



Analyse Univariée du Jeu de Données "Diamonds" avec R

*Quand la Data Brille : Exploration des
Caractéristiques des Diamants*

Réalisé par :
Ghita Salhi
Doha Essaddiki

Encadré par :
Dr. Y. FADIL

3 novembre 2025

Table des matières

1	Introduction	2
1.1	Présentation de R	2
1.2	Objectif du Projet	2
1.3	Présentation du Jeu de Données <code>diamonds</code>	2
2	Mise en Place de l'Environnement de Travail	2
2.1	Installation et Chargement des Packages	2
2.2	Chargement et Exploration Initiale des Données	3
3	Analyse Descriptive des Variables Quantitatives	3
3.1	Statistiques Descriptives	3
3.2	Visualisation par Histogrammes	4
3.2.1	Distribution du Prix	5
3.2.2	Distribution du Poids (Carat)	5
3.2.3	Distribution de la Profondeur	5
3.3	Analyse de la Dispersion et des Valeurs Aberrantes	7
3.3.1	Dispersion du Prix	7
4	Analyse Descriptive des Variables Qualitatives	7
4.1	Analyse des Fréquences	7
4.2	Visualisation par Diagrammes en Barres	8
5	Conclusion	11
A	Annexes	12
A.1	Code R Complet pour l'Analyse et la Génération des Graphiques	12
A.2	Glossaire des Termes Statistiques	14
A.3	Références	14

1. Introduction

1.1. Présentation de R

R est un langage de programmation et un environnement logiciel libre, devenu une référence mondiale pour le traitement de données, l'analyse statistique et la représentation graphique. Sa puissance réside dans sa flexibilité, sa vaste collection de packages (comme `ggplot2` et `dplyr`) et une communauté internationale très active. Ces atouts en font un outil incontournable pour les data scientists, les statisticiens et les chercheurs.

1.2. Objectif du Projet

🎯 Objectif du Projet

L'objectif central de ce projet est de conduire une **analyse univariée** rigoureuse et exhaustive du jeu de données **diamonds**. L'analyse univariée constitue la première étape fondamentale de toute exploration de données : elle nous permet de comprendre chaque variable individuellement avant d'étudier leurs interactions. Nous décrirons la distribution, la tendance centrale et la dispersion de chaque caractéristique des diamants à l'aide de statistiques descriptives et de visualisations graphiques ciblées (histogrammes, boîtes à moustaches, diagrammes en barres).

1.3. Présentation du Jeu de Données diamonds

Le dataset **diamonds**, inclus dans le célèbre package `ggplot2`, est une base de données de référence contenant des informations sur près de 54 000 diamants. La richesse de ce jeu de données provient de son volume important et de la diversité de ses variables, à la fois quantitatives (prix, poids, dimensions) et qualitatives (coupe, couleur, clarté).

TABLE 1 – Description des variables du dataset **diamonds**

Variable	Description
price	Prix en dollars américains (\$326 à \$18,823) - <i>Quantitative</i>
carat	Poids du diamant (0.2 à 5.01) - <i>Quantitative</i>
depth	Pourcentage de la profondeur totale ($z / \text{mean}(x, y)$) - <i>Quantitative</i>
table	Largeur de la facette supérieure par rapport au point le plus large - <i>Quantitative</i>
x, y, z	Dimensions en millimètres (longueur, largeur, profondeur) - <i>Quantitative</i>
cut	Qualité de la coupe (Fair, Good, Very Good, Premium, Ideal) - <i>Qualitative ordinale</i>
color	Couleur du diamant, de J (la moins bonne) à D (la meilleure) - <i>Qualitative ordinale</i>
clarity	Pureté du diamant (I1, SI2, SI1, VS2, VS1, VVS2, VVS1, IF) - <i>Qualitative ordinale</i>

2. Mise en Place de l'Environnement de Travail

2.1. Installation et Chargement des Packages

Pour cette analyse, deux packages de l'écosystème *Tidyverse* sont essentiels :

- **ggplot2** : Pour l'accès au dataset **diamonds** et la création de visualisations graphiques avancées et esthétiques.
- **dplyr** : Pour la manipulation, le filtrage et l'agrégation efficace des données, avec une syntaxe intuitive.

```
1 # Installation des packages ( ex cuter une seule fois)
2 install.packages("ggplot2")
3 install.packages("dplyr")
4
5 # Chargement des packages pour la session
6 library(ggplot2)
7 library(dplyr)
```

2.2. Chargement et Exploration Initiale des Données

Une fois les packages chargés, nous importons le jeu de données et effectuons une première inspection avec les fonctions `head()` et `str()` pour valider le chargement et vérifier le type de chaque variable.

```
1 # Chargement du jeu de donn es depuis ggplot2
2 data("diamonds")
3
4 # Afficher les 6 premi res lignes pour un aper u
5 head(diamonds)
6
7 # Obtenir un r sum de la structure du jeu de donn es (types des
  variables)
8 str(diamonds)
```

3. Analyse Descriptive des Variables Quantitatives

Nous analysons ici les variables numériques clés : **price**, **carat** et **depth**.

3.1. Statistiques Descriptives

La fonction `summarise()` de **dplyr** nous permet de calculer de manière concise les principaux indicateurs de tendance centrale (moyenne, médiane) et de dispersion (écart-type, min, max).

```
1 # Obtenir un r sum statistique pour les variables d'int r t
2 diamonds %>%
3   summarise(
4     Moyenne_Prix = mean(price),
5     Mediane_Prix = median(price),
6     Ecart_type_Prix = sd(price),
7
8     Moyenne_Carat = mean(carat),
9     Mediane_Carat = median(carat),
10    Ecart_type_Carat = sd(carat),
```

```

11
12 Moyenne_Profondeur = mean(depth),
13 Mediane_Profondeur = median(depth),
14 Ecart_type_Profondeur = sd(depth)
15 )

```

TABLE 2 – Résumé des statistiques descriptives pour les variables quantitatives.

Statistique	Prix (\$)	Carat	Profondeur (%)
Minimum	326.00	0.20	43.00
1er Quartile (Q1)	950.00	0.40	61.00
Médiane	2,401.00	0.70	61.80
Moyenne	3,932.80	0.80	61.75
3e Quartile (Q3)	5,324.25	1.04	62.50
Maximum	18,823.00	5.01	79.00
Écart-type	3,989.44	0.47	1.43



Interprétation

- **Prix (Price)** : La moyenne (3,933\$) est très largement supérieure à la médiane (2,401\$). C'est le signe caractéristique d'une **distribution asymétrique à droite** (positive skew). Un petit nombre de diamants de luxe, très chers, tirent la moyenne vers le haut. La médiane est donc un indicateur plus représentatif du prix d'un diamant "typique". L'écart-type, presque aussi grand que la moyenne, confirme l'extrême dispersion des prix.
- **Poids (Carat)** : Le même phénomène s'observe. La moyenne (0.80) est supérieure à la médiane (0.70), indiquant que la majorité des diamants sont de petite taille (moins de 0.7 carat), tandis qu'une minorité de gros diamants augmente la moyenne.
- **Profondeur (Depth)** : La moyenne (61.75%) et la médiane (61.8%) sont presque identiques. Cela suggère une **distribution très symétrique, proche de la normale**. Le faible écart-type (1.43) indique que la profondeur est une caractéristique très standardisée dans l'industrie, probablement pour optimiser la brillance du diamant.

3.2. Visualisation par Histogrammes

Les histogrammes confirment visuellement les observations issues des statistiques descriptives.




FIGURE 1 – Histogramme de la distribution des prix.

3.2.1. Distribution du Prix



Interprétation

Le graphique montre clairement une forte concentration de diamants dans les gammes de prix inférieures ($< 5,000\$$), suivie d'une longue queue de distribution vers la droite. Ceci confirme l'asymétrie et la présence de diamants de très grande valeur, mais en faible nombre.

3.2.2. Distribution du Poids (Carat)



Interprétation

La distribution du carat est également asymétrique à droite. On observe des pics très nets sur des valeurs "psychologiques" ou commerciales (ex : 0.3, 0.5, 0.7, 1.0 carat), ce qui suggère que les diamants sont souvent taillés pour atteindre ces poids de référence.

3.2.3. Distribution de la Profondeur



Interprétation

Cet histogramme présente une distribution quasi-normale (en forme de cloche), parfaitement symétrique et centrée autour de 62%. Ceci confirme que la grande majorité des diamants respectent un standard de profondeur très précis, avec très peu d'écarts extrêmes.




FIGURE 2 – Histogramme de la distribution du poids en carats.




FIGURE 3 – Histogramme de la distribution de la profondeur.

3.3. Analyse de la Dispersion et des Valeurs Aberrantes

Les boîtes à moustaches (boxplots) sont un outil puissant pour visualiser la dispersion (l'Intervalle Inter-Quartile, IQR) et identifier les valeurs aberrantes.

```

1 # Calculer le nombre de valeurs aberrantes pour le prix
2 Q1 <- quantile(diamonds$price, 0.25)
3 Q3 <- quantile(diamonds$price, 0.75)
4 IQR_value <- IQR(diamonds$price)
5 # Une valeur est aberrante si elle est > Q3 + 1.5 * IQR ou < Q1 -
  1.5 * IQR
6 outliers <- diamonds %>% filter(price > (Q3 + 1.5 * IQR_value))
7 nrow(outliers)
8 # [1] 3540

```

3.3.1. Dispersion du Prix




FIGURE 4 – Boîte à moustaches du prix.



Interprétation

La boîte est étirée, confirmant une forte dispersion des prix. La ligne de la médiane est située dans la partie inférieure de la boîte, visualisant l'asymétrie à droite. Les nombreux points au-dessus de la moustache supérieure sont identifiés comme des valeurs aberrantes. Dans ce contexte, il ne s'agit pas d'erreurs de données, mais bien de la représentation du segment des diamants de luxe, dont le prix est exceptionnellement élevé par rapport à la majorité du marché.

4. Analyse Descriptive des Variables Qualitatives

Nous étudions la répartition des diamants selon leurs caractéristiques ordinales : la coupe (cut), la couleur (color) et la clarté (clarity).

4.1. Analyse des Fréquences

Nous calculons les fréquences absolues (nombre d'occurrences) et relatives (pourcentage) pour chaque catégorie.


```

1 # Fréquences relatives (en %) pour la variable 'cut'
2 round(prop.table(table(diamonds$cut)) * 100, 2)
3 # Fréquences relatives (en %) pour la variable 'color'
4 round(prop.table(table(diamonds$color)) * 100, 2)
5 # Fréquences relatives (en %) pour la variable 'clarity'
6 round(prop.table(table(diamonds$clarity)) * 100, 2)

```

TABLE 3 – Distribution des fréquences pour les variables qualitatives.

Variable	Catégorie	Fréq. Absolue	Fréq. Relative (%)
Coupe (Cut)	Ideal	21,551	39.95
	Premium	13,791	25.57
	Very Good	12,082	22.40
	Good	4,906	9.10
	Fair	1,610	2.98
Couleur (Color)	G	11,292	20.94
	E	9,797	18.16
	F	9,542	17.69
	...	...	...
Clarté (Clarity)	SI1	13,065	24.23
	VS2	12,258	22.73
	SI2	9,194	17.05
	...	...	...

💡 Interprétation

- **Coupe** : Une part écrasante des diamants (près de 40%) possède une coupe "Ideal", la meilleure qualité possible. Les coupes de haute qualité (Ideal, Premium, Very Good) représentent plus de 87% du jeu de données, ce qui suggère que ce dataset se concentre sur des diamants de qualité joaillerie.
- **Couleur** : La distribution est centrée sur les couleurs intermédiaires (G, E, F). Les couleurs les plus pures (D, "incoloré") et les moins pures (J, légère teinte) sont plus rares.
- **Clarté** : Les catégories "Slightly Included" (SI1, SI2) et "Very Slightly Included" (VS2, VS1) sont les plus fréquentes. Les diamants d'une pureté parfaite ("Internally Flawless", IF) ou présentant des inclusions visibles (I1) sont très rares.

4.2. Visualisation par Diagrammes en Barres

Les diagrammes en barres permettent de visualiser rapidement la répartition des catégories.




FIGURE 5 – Distribution de la qualité de la coupe (de la moins bonne à la meilleure).




FIGURE 6 – Distribution de la couleur des diamants (de la meilleure à la moins bonne).

5. Conclusion

✓ Synthèse et Conclusion

L'analyse univariée du jeu de données **diamonds** a mis en lumière des profils clairs et distincts pour chaque variable, nous permettant de broser un portrait détaillé du marché des diamants représenté dans cet échantillon.

- **Profil du Diamant Type** : Le diamant le plus courant dans ce dataset est de **petite taille** (médiane à 0.7 carat), possède une **coupe d'excellente qualité** (majoritairement "Ideal"), une **couleur quasi incolore** (G) et une **clarté avec de très légères inclusions** (SI1 ou VS2). Sa profondeur est presque certainement standardisée autour de 62%.
- **Asymétrie et Rareté des Biens de Luxe** : Les distributions du **prix** et du **poids** sont fortement asymétriques à droite. Cette forme est typique des marchés de biens de consommation incluant un segment de luxe : une vaste majorité de produits sont abordables, tandis qu'une minorité d'articles, rares et exceptionnels, atteignent des prix très élevés. Pour ces variables, la **médiane est un indicateur de tendance centrale beaucoup plus robuste** et représentatif que la moyenne.
- **Standardisation vs. Variabilité** : Une dichotomie claire apparaît. Des caractéristiques comme la **profondeur** sont très standardisées, avec une faible dispersion, ce qui témoigne de normes techniques dans l'industrie. À l'opposé, le **prix** et le **carat** affichent une variabilité immense, reflétant la diversité naturelle et la segmentation du marché.
- **Biais d'Échantillonnage Possible** : Le dataset est majoritairement composé de diamants de haute qualité, notamment en ce qui concerne la coupe. Il est donc probable que cet échantillon ne représente pas l'ensemble des diamants extraits, mais plutôt ceux qui sont sélectionnés pour la joaillerie.

Perspectives : Cette analyse univariée est le socle indispensable pour des explorations plus complexes. Les prochaines étapes logiques incluent des analyses bivariées (ex : corrélation entre le prix et le carat via un nuage de points, impact de la coupe sur le prix via des boxplots groupés) et multivariées pour construire des modèles prédictifs du prix en fonction de l'ensemble de ses caractéristiques.

A. Annexes

A.1. Code R Complet pour l'Analyse et la Génération des Graphiques

```

1 # =====
2 # MINI-PROJET R : ANALYSE UNIVARIÉE DIAMONDS
3 # =====
4
5 # --- 1. MISE EN PLACE ---
6 # Installation des packages ( ex cuter une seule fois)
7 install.packages("ggplot2")
8 install.packages("dplyr")
9
10 # Chargement des packages
11 library(ggplot2)
12 library(dplyr)
13
14 # Chargement et exploration initiale des donn es
15 data("diamonds")
16 head(diamonds)
17 str(diamonds)
18 cat("Nombre total d'observations :", nrow(diamonds))
19
20
21 # --- 2. ANALYSE DES VARIABLES QUANTITATIVES ---
22
23 # Calcul des statistiques descriptives avec dplyr
24 diamonds %>%
25   summarise(
26     Moyenne_Prix = mean(price), Mediane_Prix = median(price),
27     Ecart_type_Prix = sd(price),
28     Min_Prix = min(price), Max_Prix = max(price),
29
30     Moyenne_Carat = mean(carat), Mediane_Carat = median(carat),
31     Ecart_type_Carat = sd(carat),
32     Min_Carat = min(carat), Max_Carat = max(carat),
33
34     Moyenne_Profondeur = mean(depth), Mediane_Profondeur = median
35     (depth), Ecart_type_Profondeur = sd(depth),
36     Min_Profondeur = min(depth), Max_Profondeur = max(depth)
37   )
38
39 # Calcul des quantiles et de l'IQR
40 quantile(diamonds$price, probs = c(0.25,0.5, 0.75))
41 IQR(diamonds$price)
42 var(diamonds$price)
43
44 # --- 3. ANALYSE DES VARIABLES QUALITATIVES ---

```

```

43
44 # Fréquences absolues et relatives pour 'cut'
45 table(diamonds$cut)
46 prop.table(table(diamonds$cut)) * 100
47
48 # Fréquences pour 'color'
49 table(diamonds$color)
50 prop.table(table(diamonds$color)) * 100
51
52 # Fréquences pour 'clarity'
53 table(diamonds$clarity)
54 prop.table(table(diamonds$clarity)) * 100
55
56
57 # --- 4. DÉTECTION DES VALEURS ABERRANTES ---
58 Q1 <- quantile(diamonds$price, 0.25)
59 Q3 <- quantile(diamonds$price, 0.75)
60 IQR_value <- IQR(diamonds$price)
61 outliers <- diamonds$price[diamonds$price < (Q1 - 1.5*IQR_value) |
62                               diamonds$price > (Q3 + 1.5*IQR_value)]
63 cat("Nombre de valeurs aberrantes pour le prix :", length(outliers)
64     )
65
66 # --- 5. GÉNÉRATION DES GRAPHIQUES (avec sauvegarde en PNG) ---
67
68 # Histogrammes
69 png("hist_prix.png", width=800, height=600)
70 hist(diamonds$price, breaks = 50, col = "steelblue", main = "
71     Distribution du prix", xlab = "Prix", ylab="Fréquence", border=
72     "white")
73 dev.off()
74
75 png("hist_carat.png", width=800, height=600)
76 hist(diamonds$carat, breaks = 50, col = "coral", main = "
77     Distribution du carat", xlab = "Carat", ylab="Fréquence",
78     border="white")
79 dev.off()
80
81 png("hist_profondeur.png", width=800, height=600)
82 hist(diamonds$depth, breaks = 50, col = "lightgreen", main = "
83     Distribution de la profondeur", xlab = "Profondeur (%)", ylab="
84     Fréquence", border="white")
85 dev.off()
86
87 # Boîtes moustaches
88 png("boxplot_prix.png", width=500, height=700)
89 boxplot(diamonds$price, main="Boîte moustaches du prix", ylab="
90     Prix ($)", col="lightblue")
91 dev.off()
92

```

```

86 png("boxplot_carat.png", width=500, height=700)
87 boxplot(diamonds$carat, main="Boîte à moustaches du carat", ylab="
    Carat", col="lightcoral")
88 dev.off()
89
90 # Diagrammes en barres
91 png("barchart_cut.png", width=800, height=600)
92 barplot(table(diamonds$cut), col=rainbow(5), main="Répartition
    selon la coupe", ylab="Fréquence", xlab="Type de coupe")
93 dev.off()
94
95 png("barchart_color.png", width=800, height=600)
96 barplot(table(diamonds$color), col=terrain.colors(7), main="
    Répartition selon la couleur", ylab="Fréquence", xlab="Couleur
    ")
97 dev.off()

```

Listing 1 – Script R complet utilisé pour le rapport

A.2. Glossaire des Termes Statistiques

Asymétrie à droite (Right Skew) Distribution où la majorité des valeurs sont faibles, mais où quelques valeurs très élevées "étirent" la distribution vers la droite. Dans ce cas, Moyenne > Médiane.

Boîte à Moustaches (Boxplot) Représentation graphique synthétisant une distribution via cinq indicateurs : minimum, premier quartile (Q1), médiane (Q2), troisième quartile (Q3) et maximum.

Écart-type (Standard Deviation) Mesure de la dispersion moyenne des valeurs d'un ensemble de données par rapport à sa moyenne. Un écart-type élevé signifie une grande variabilité.

Intervalle Interquartile (IQR) Différence entre le troisième (Q3) et le premier (Q1) quartile ($IQR = Q3 - Q1$). Il mesure la dispersion des 50% centraux des données et est robuste aux valeurs extrêmes.

Médiane Valeur centrale qui sépare un ensemble de données ordonné en deux moitiés égales. Contrairement à la moyenne, elle n'est pas influencée par les valeurs aberrantes.

Valeur Aberrante (Outlier) Observation qui s'écarte significativement des autres observations. Dans un boxplot, elle est souvent définie comme étant à plus de 1.5 fois l'IQR en dehors des quartiles Q1 ou Q3.

A.3. Références

Références

- [1] Wickham, H. (2016). *ggplot2 : Elegant Graphics for Data Analysis*. Springer-Verlag New York.
- [2] R Core Team (2023). *R : A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. URL : <https://www.R-project.org/>

[3] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.